

RAPPORT D'ANALYSE DE DONNÉES

Projet de modélisation statistique – secteur du Bâtiment et Travaux
Publics

Analyse exploratoire, classification et détection d'anomalies sur 1 000 projets BTP

ACP · K-Means · Forêt aléatoire · ACM · Isolation Forest / LOF

Auteur : Achraf AIT LAHCEN

Jeu de données : Construction-BTP_Dataset_AFC.xlsx

Taille : 1 000 projets × 27 variables (21 quantitatives + 6 qualitatives)

Outils : Python – pandas, scikit-learn, prince, seaborn

Date : 1^{er} septembre 2026

Table des matières

1	Introduction et contexte	1
1.1	Objectif du projet	1
1.2	Jeu de données	1
1.3	Méthodologie générale	2
2	Statistiques descriptives et corrélations	3
2.1	Préparation des données	3
2.2	Statistiques descriptives	3
2.3	Matrice de corrélation	3
3	Analyse en Composantes Principales (ACP)	5
3.1	Inertie expliquée	5
3.2	Structure des axes 1 et 2	5
3.3	Plan factoriel des individus	7
3.4	Qualité de représentation et cercle des corrélations	8
3.5	Contribution des variables aux axes	10
4	Classification non supervisée (K-Means)	11
4.1	Sélection du nombre de clusters	11
4.2	Résultat de la classification	12
4.3	Profils moyens des clusters	13
5	Modélisation prédictive (forêt aléatoire)	14
5.1	Protocole	14
5.2	Résultats	14
6	Simulation de nouveaux projets	15
6.1	Scénarios simulés	15
6.2	Résultats	15
7	Analyse des Correspondances Multiples (ACM)	16
7.1	Variables qualitatives mobilisées	16
7.2	Inertie expliquée	16
7.3	Plan factoriel des modalités	17
7.4	Contributions aux axes	18
8	Détection d'anomalies	19
8.1	Protocole	19
8.2	Résultats	19

9	Synthèse, limites et recommandations	21
9.1	Synthèse des résultats	21
9.2	Limites	21
9.3	Recommandations	21
	Annexes	23

1. Introduction et contexte

1.1 Objectif du projet

Ce rapport présente une analyse statistique complète d'un jeu de données de **1 000 projets de construction (BTP)**. L'objectif est double :

- (i) explorer la structure statistique des variables quantitatives décrivant les projets (coût, ressources, caractéristiques du bâtiment, qualité/sécurité, environnement) à l'aide d'une Analyse en Composantes Principales (ACP) et d'une classification non supervisée (K-Means) ;
- (ii) exploiter des variables qualitatives complémentaires (type de projet, statut, client, certification, matériau, région) au moyen d'une Analyse des Correspondances Multiples (ACM), et détecter les chantiers présentant un profil de risque atypique.

Une modélisation prédictive (forêt aléatoire) et un exercice de simulation (positionnement de nouveaux projets fictifs) complètent l'analyse descriptive.

1.2 Jeu de données

Le jeu de données comprend **21 variables quantitatives**, regroupées en 6 catégories métier, et **6 variables qualitatives** ajoutées dans un second temps pour permettre l'ACM :

Catégorie	Variables
Projet	Coût estimé, Coût réel, Durée, Avancement (%)
Ressources	Quantité de matériaux, Heures de travail, Équipements, Conso. énergétique
Caractéristiques bâtiment	Surface, Étages, Volume, Hauteur, Indice de perf. énergétique, Conso. annuelle
Qualité / Sécurité	Nombre d'incidents, Nombre d'accidents
Environnement	Déchets, Émissions CO2, Conso. d'eau, Niveau sonore
Données complémentaires	Note de satisfaction client
<i>Variables qualitatives (ACM)</i>	Type de projet, Statut, Type de client, Certification env., Matériau, Région

Table 1.1 – Structure des variables du jeu de données.

Point clé – Les 6 variables qualitatives ont été générées pour compléter le jeu de données quantitatif initial, avec des règles probabilistes les reliant partiellement aux variables quantitatives (ex. le *Type de projet* dépend de la surface et du nombre d'équipements). Cela permet à l'ACM de révéler des correspondances interprétables plutôt que du seul bruit – voir chapitre 7.

1.3 Méthodologie générale

Le pipeline d'analyse, implémenté en Python, se décompose en huit étapes :

1. Statistiques descriptives et matrice de corrélation ;
2. Analyse en Composantes Principales (ACP) sur les 21 variables quantitatives standardisées ;
3. Classification K-Means avec sélection automatique de K (méthode du coude et score de silhouette) ;
4. Modélisation prédictive par forêt aléatoire (composantes principales $\rightarrow$ variables originales) ;
5. Simulation et positionnement de 3 nouveaux projets fictifs ;
6. Représentation combinée projets existants / nouveaux projets ;
7. Analyse des Correspondances Multiples (ACM) sur les 6 variables qualitatives ;
8. Détection d'anomalies (Isolation Forest et Local Outlier Factor) sur les indicateurs de risque.

Remarque méthodologique : l'ensemble des résultats chiffrés et figures de ce rapport ont été obtenus en ré-exécutant fidèlement le pipeline (mêmes paramètres, mêmes graines aléatoires `random_state=42`) afin de garantir leur exactitude et leur reproductibilité.

2. Statistiques descriptives et corrélations

2.1 Préparation des données

Après conversion des colonnes en type numérique et suppression des lignes incomplètes, les **1 000 lignes** du jeu de données sont toutes conservées (aucune valeur manquante détectée après nettoyage). L'analyse porte donc sur l'intégralité de l'échantillon.

2.2 Statistiques descriptives

Le tableau ?? résume la moyenne, l'écart-type, le minimum et le maximum de chacune des 21 variables quantitatives. Les coûts (estimé et réel) se situent en moyenne autour de 250 000 DH avec un écart-type de l'ordre de 60 000 DH, tandis que les variables de qualité/sécurité (incidents, accidents) restent proches de 1 en moyenne, ce qui indique un profil de risque globalement modéré sur l'ensemble de l'échantillon.

2.3 Matrice de corrélation

La matrice de corrélation (figure 2.1) est calculée sur les 21 variables standardisées.




Figure 2.1 – Matrice de corrélation des 21 variables quantitatives.

Point clé – Sur les 210 paires de variables possibles, une seule présente une corrélation forte : **Coût estimé / Coût réel** ($r = 0,96$). Toutes les 209 autres paires affichent une corrélation quasi nulle ($|r| \leq 0,09$). Le jeu de données est donc, par construction, très proche de l'indépendance statistique en dehors du couple des coûts – un point qui conditionne fortement l'interprétation de l'ACP et de la classification présentées ci-après.

3. Analyse en Composantes Principales (ACP)

3.1 Inertie expliquée

Après standardisation (moyenne nulle, écart-type unitaire), l'ACP est calculée sur les 21 axes possibles. La figure 3.1 montre la part d'inertie expliquée par chaque composante et son cumul.




Figure 3.1 – Inertie expliquée et inertie cumulée par composante principale.

La première composante n'explique que **9,4 %** de l'inertie totale, la deuxième **6,2 %** ; il faut cumuler **16 composantes sur 21** pour atteindre 80 % de l'inertie. Cette décroissance quasi linéaire (et non en « coude » marqué) est la signature directe de l'absence de corrélation entre variables observée au chapitre précédent : quand les variables sont indépendantes, aucune ne peut être « résumée » par les autres, et l'inertie se répartit presque uniformément sur tous les axes.

3.2 Structure des axes 1 et 2

Le tableau des *loadings* (figure 3.2) montre la contribution de chaque variable aux 6 premières composantes.




Figure 3.2 – Coefficients (loadings) des variables sur les 6 premières composantes principales.

Point clé – L’axe 1 est un « axe du coût » quasi pur : Coût estimé et Coût réel y contribuent à eux seuls pour **98,3 %** (49,2 % + 49,1 %, figure 3.6), avec des coefficients de 0,70 chacun. L’axe 2 est plus diffus : il combine Durée du projet (15,0 %), Niveau sonore (14,5 %) et Surface totale (9,9 %), sans qu’aucune variable ne domine véritablement.

3.3 Plan factoriel des individus




Figure 3.3 – Projection des 1 000 projets sur le plan (PC1, PC2).

Le nuage de points est globalement homogène et sans structure de groupes visible à l'œil nu : les individus se répartissent en un nuage continu centré sur l'origine, cohérent avec des données standardisées sans corrélation forte hormis le coût.

3.4 Qualité de représentation et cercle des corrélations




Figure 3.4 – Qualité de représentation ($\cos^2$) des variables sur les axes 1 et 2.




Figure 3.5 – Cercle des corrélations (PC1-PC2). Numérotation des variables en annexe (tableau 9.1).

Point clé – Seules les variables de coût sont bien représentées sur le plan 1-2 ($\cos^2 \approx 0,97$). Toutes les autres variables ont un $\cos^2$ inférieur à 0,20 sur ces deux axes : leurs flèches restent très proches du centre du cercle des corrélations (figure 3.5), ce qui signifie que le plan (PC1, PC2) ne capture presque rien de leur variance – il faudrait mobiliser des axes de rang plus élevé pour les représenter fidèlement.

3.5 Contribution des variables aux axes




Figure 3.6 – Contribution des variables aux axes 1 et 2 (%).

4. Classification non supervisée (K-Means)

4.1 Sélection du nombre de clusters

Le nombre optimal de clusters K est recherché automatiquement sur $K \in \{2, \dots, 10\}$, en combinant la méthode du coude (inertie intra-classe) et le score de silhouette, calculés sur les deux premières composantes principales.




Figure 4.1 – Méthode du coude et score de silhouette pour $K \in \{2, \dots, 10\}$.

Le score de silhouette est maximal pour $K = 2$ (**0,414**), puis décroît et oscille entre 0,33 et 0,38 pour $K \geq 3$. Le modèle retient donc $K = 2$ comme partition optimale.

4.2 Résultat de la classification




Figure 4.2 – Projection des deux clusters sur le plan factoriel (PC1, PC2).




Figure 4.3 – Répartition des projets entre les deux clusters.

La partition sépare le nuage quasiment le long de l'axe 1 (l'axe du coût), en deux groupes de taille très proche : **Cluster 0** (505 projets, 50,5 %) et **Cluster 1** (495 projets, 49,5 %).

4.3 Profils moyens des clusters




Figure 4.4 – Profils moyens (valeurs brutes) des deux clusters.

Point clé – L'écart entre les deux clusters porte presque exclusivement sur le **budget** : coût estimé moyen de 300 666 DH (Cluster 0) contre 199 192 DH (Cluster 1), soit un écart de +51 %. Sur les 19 autres variables, les moyennes des deux clusters sont quasi identiques (écarts inférieurs à 5 % partout). La classification K-Means, appliquée à ce jeu de données, revient donc essentiellement à séparer les « gros » et les « petits » budgets, sans faire émerger d'autre profil-type de chantier – ce qui est cohérent avec l'absence de corrélation constatée au chapitre 2.

5. Modélisation prédictive (forêt aléatoire)

5.1 Protocole

Une forêt aléatoire multi-sorties (`MultiOutputRegressor(RandomForestRegressor)`, 100 arbres) est entraînée pour prédire les **21 variables originales** à partir des **4 premières composantes principales** uniquement. Le jeu est séparé en apprentissage (70 %) et test (30 %), avec `random_state=42`.

5.2 Résultats

Le tableau ?? présente le score R^2 obtenu en apprentissage et en test pour chacune des 21 variables, trié par R^2 test décroissant.

Point clé – Le modèle obtient un très bon score en test uniquement pour les deux variables de coût ($R^2_{\text{test}} = 0,970$ et **0,967**) – attendu puisque PC1 est presque entièrement déterminé par elles. Pour les 19 autres variables, le R^2 test moyen tombe à **0,12**, avec plusieurs valeurs négatives (le modèle fait pire qu’une simple prédiction par la moyenne), alors que le R^2 train reste élevé (moyenne 0,88) pour toutes les variables. Cet écart massif entre apprentissage et test est un cas d’école de **surapprentissage** : la forêt aléatoire mémorise le bruit d’entraînement plutôt que d’apprendre une relation généralisable, ce qui est cohérent avec l’absence de structure corrélative dans les données en dehors du coût. Ce modèle ne devrait donc pas être utilisé en l’état pour prédire autre chose que le coût.

6. Simulation de nouveaux projets

6.1 Scénarios simulés

Trois projets fictifs sont définis manuellement pour illustrer le positionnement de nouveaux chantiers dans l'espace factoriel appris (même `scaler`, même ACP, même modèle K-Means, sans ré-entraînement) :

- **Projet A** – grand projet coûteux (450 000 DH estimés, 3 500 m², 10 étages) ;
- **Projet B** – projet de taille moyenne (220 000 DH, 1 300 m²) ;
- **Projet C** – petit projet (150 000 DH, 800 m²).

6.2 Résultats




Figure 6.1 – Positionnement des 3 nouveaux projets sur le plan factoriel des projets existants.

Le Projet A, nettement plus coûteux, se projette très à droite sur l'axe 1 et est affecté au **Cluster 0** (gros budgets). Les projets B et C, moins coûteux, sont affectés au **Cluster 1**, avec le Projet C plus éloigné encore sur l'axe 1 du fait de son budget plus faible. Ce résultat confirme, sur des cas concrets, que la frontière entre les deux clusters est essentiellement une frontière de coût.

7. Analyse des Correspondances Multiples (ACM)

7.1 Variables qualitatives mobilisées

L'ACM porte sur les 6 variables qualitatives ajoutées au jeu de données (26 modalités au total); leurs effectifs sont détaillés dans le tableau ??.

7.2 Inertie expliquée




Figure 7.1 – Inertie expliquée par les deux premiers axes de l'ACM.

Les deux premiers axes expliquent respectivement **9,35 %** et **7,04 %** de l'inertie totale. Ces valeurs, faibles en apparence, sont **normales en ACM** dès lors que le nombre de modalités est important (26 ici) : l'inertie totale se répartit sur un grand nombre d'axes, et une part de 15-20 % cumulée sur les deux premiers axes est un résultat courant et exploitable.

7.3 Plan factoriel des modalités




Figure 7.2 – Plan factoriel de l'ACM – positionnement des modalités.

Point clé – Contrairement au nuage homogène observé en ACP, le plan de l'ACM fait apparaître une structure de correspondance nette et interprétable : l'**axe 1** oppose les projets d'**Infrastructure** et les clients **Publics** (à droite) aux projets **Résidentiels**, en matériau **Bois**, avec client **Privé** (à gauche). L'**axe 2** oppose les projets **Résidentiel/Bois** (en haut) aux statuts **Suspendu** et à la région **Fès-Meknès** (en bas). Cette structure n'est pas fortuite : elle reflète directement les règles de génération des variables qualitatives (le type de client et le matériau ont été simulés en fonction du type de projet), ce qui valide la cohérence interne du jeu de données enrichi.

7.4 Contributions aux axes




Figure 7.3 – Top 15 des contributions des modalités aux axes 1 et 2.

Les modalités *Type de client – Public* (22,1 %) et *Type de projet – Infrastructure* (21,4 %) dominent l'axe 1; *Type de projet – Résidentiel* (16,2 %) et *Matériau – Bois* (14,5 %) dominent l'axe 2, confirmant la lecture du plan factoriel ci-dessus.

8. Détection d'anomalies

8.1 Protocole

Deux algorithmes non supervisés sont appliqués en parallèle sur 4 indicateurs de risque – **nombre d'incidents**, **nombre d'accidents**, **durée du projet** et **dépassement budgétaire** (Coût réel – Coût estimé), normalisés par un `MinMaxScaler` :

- **Isolation Forest** (contamination = 10 %) – isole les points par partitionnement aléatoire récursif ;
- **Local Outlier Factor** (LOF, $k = 5$ voisins, contamination = 10 %) – mesure un écart de densité locale.

8.2 Résultats




Figure 8.1 – Chantiers signalés comme anormaux (en rouge) par Isolation Forest et LOF.

Indicateur	Valeur
Chantiers analysés	1 000
Signalés par au moins une méthode (union)	161 (16,1 %)
Signalés par les deux méthodes simultanément	39 (3,9 %)

Table 8.1 – Synthèse de la détection d'anomalies.

Point clé – Les deux méthodes s'accordent sur seulement 39 chantiers (24 % des 161 signalements), ce qui est attendu : Isolation Forest et LOF reposent sur des principes différents (partitionnement aléatoire contre densité locale) et ne signalent pas systématiquement les mêmes points. Les chantiers flaggés se concentrent, sans surprise, sur les dépassements budgétaires les plus extrêmes (au-delà de $\pm 20\,000$ DH environ), répartis de manière assez homogène sur les nombres d'accidents (0, 1 ou 2).

Remarque technique : l'axe des ordonnées du script original étiquette le dépassement budgétaire en « MDH » (millions de dirhams), alors que les valeurs tracées (de l'ordre de 10^3 à 10^4) correspondent en réalité à des **dirhams (DH)**. Ce libellé a été corrigé dans les figures de ce rapport ; il est recommandé de corriger également le script source.

9. Synthèse, limites et recommandations

9.1 Synthèse des résultats

- Le jeu de données quantitatif est, hormis le couple Coût estimé/Coût réel ($r = 0,96$), très proche de l'indépendance statistique (209 paires sur 210 avec $|r| \leq 0,09$).
- L'ACP reflète directement ce constat : l'axe 1 (9,4 % d'inertie) est un axe de coût quasi pur, et il faut 16 composantes pour atteindre 80 % d'inertie cumulée.
- La classification K-Means retient $K = 2$ (silhouette = 0,414) et sépare essentiellement les gros et petits budgets (+51 % d'écart de coût moyen entre clusters, toutes les autres variables étant quasi identiques).
- La forêt aléatoire prédit très bien le coût ($R^2_{\text{test}} \approx 0,97$) mais surapprend sur toutes les autres variables (R^2_{test} moyen de 0,12, parfois négatif).
- L'ACM sur les 6 variables qualitatives révèle en revanche une structure de correspondance claire et interprétable (type de projet $\leftrightarrow$ type de client $\leftrightarrow$ matériau), cohérente avec les règles de génération de ces variables.
- La détection d'anomalies signale 161 chantiers à risque (16,1 %), principalement liés à des dépassements budgétaires extrêmes.

9.2 Limites

- Le jeu de données quantitatif est synthétique et généré sans corrélation volontaire entre variables (hormis coût estimé/réel) : les résultats de l'ACP, du K-Means et de la forêt aléatoire reflètent donc surtout cette absence de structure, et non un phénomène métier réel.
- Les variables qualitatives, elles, ont été générées avec des dépendances probabilistes volontaires vis-à-vis des variables quantitatives : les correspondances observées en ACM sont donc en partie « programmées » et devraient être revalidées sur des données réelles.
- Le seuil de contamination (10 %) pour la détection d'anomalies est un choix arbitraire et devrait être ajusté selon un retour terrain (taux réel de chantiers problématiques).

9.3 Recommandations

1. Sur données réelles, privilégier une régression ciblée du coût plutôt qu'un modèle multi-sorties sur l'ensemble des 21 variables, dont la plupart ne sont pas prédictibles à partir des composantes principales actuelles.

2. Enrichir le jeu de données quantitatif avec des dépendances métier réalistes (ex. surface $\rightarrow$ coût, durée $\rightarrow$ heures de travail) afin que l'ACP et le clustering apportent une valeur explicative au-delà du seul budget.
3. Corriger l'unité affichée du dépassement budgétaire (DH, et non MDH) dans le script source.
4. Valider le seuil de contamination des modèles d'anomalies avec les équipes sécurité/chantier avant tout usage opérationnel.

Annexes

A.1 – Légende du cercle des corrélations

N°	Variable
1	Coût estimé
2	Coût réel
3	Durée du projet (en jours)
4	Avancement (%)
5	Quantité des matériaux (kg, m3)
6	Heures de travail
7	Nombre d'équipements utilisés
8	Consommation énergétique (kWh)
9	Surface totale (m ²)
10	Nombre d'étages
11	Volume (m3)

N°	Variable
12	Hauteur (m)
13	Indice de performance énergétique
14	Consommation énergétique annuelle (kWh)
15	Nombre d'incidents
16	Nombre d'accidents
17	Volume déchets produits (kg)
18	Émissions CO2 (kg)
19	Consommation d'eau (m3)
20	Niveau sonore (dB)
21	Note satisfaction client

Table 9.1 – Correspondance numéro ↔ variable (figure 3.5).

A.2 – Fichiers produits

- `projets_BTP_complets_avec_clusters.xlsx` – jeu de données complet avec PC1, PC2 et cluster ;
- `random_forest_r2.csv` – scores R^2 détaillés par variable ;
- `alertes_chantiers_anormaux.xlsx` – liste des chantiers signalés comme anormaux ;
- `cluster_profiles.csv`, `descriptive_stats.csv` – tableaux numériques sources de ce rapport.